

## Лабораторная работа #2

### Анализ исполняемых файлов

Цель: узнать, "что там внутри" у программ, написанных на С или С++.

## 0. Введение в дизассемблирование

### Установка зависимостей и ПО

```
x@vbox:~$ sudo apt install -y linux-headers-$(uname -r)
x@vbox:~$ sudo apt install -y build-essential
x@vbox:~$ sudo apt install -y gcc-multilib
x@vbox:~$ sudo apt install -y g++-multilib
```

### gcc

Все тестовые примеры, с которыми мы будем работать в этой лабораторной работе (исходники находятся в папке *examples*), необходимо будет компилировать с помощью **gcc** [1-2]. Приведём полезные ключи этого компилятора:

- **-o prog\_name** – указание создать исполняемый файл с именем *prog\_name*
- **-m32** – собрать под архитектуру x86 (32-битный исполняемый файл)
- **-g** – собрать с отладочными символами, это сохраняет в числе прочего информацию о названиях функций и переменных.

### gdb

Для отладки исполняемого файла можно и нужно использовать отладчик **gdb** [3-9]. Полезные команды:

- **set disassembly-flavor intel**  
устанавливает вывод кода в синтаксисе intel (это нормальный), а не AT&T (это ненормальный)
- **disas**  
**disas main**  
**disas <label>**  
декомпилировать (показать ассемблерный листинг) текущую функцию, функцию *main* или функцию по метке *label*, соответственно
- **break main**  
**break <label>**  
**break \*0x4005ea**  
установить точку останова на начало функции *main*, на метку *label* или на адрес *0x4005ea*, соответственно
- **d n**  
удалить точку останова под номером *n*
- **start**  
запустить на выполнение бинарник
- **s**  
**step**  
сделать шаг (во время отладки)

- **si**  
**si n**  
выполнить текущую инструкцию, соответственно выполнить n инструкций (можно задавать любое число)
- **u \*0x400546**  
продолжить выполнение до инструкции по адресу 0x400546
- **i r**  
**i r <reg\_name>**  
вывести содержимое всех регистров или регистра reg\_name
- **x/5a \$rsp**  
**x/5s \*0x600342**  
**x/5w \*0x600a0c**  
вывести 5 указателей на вершине стека (в памяти по адресу, хранимому в **rsp**), вывести 5 нуль завершённых строк по адресу 0x600342, вывести 6 4-байтных числа по адресу 0x600a0c.

## IDA

Interactive Disassembler, **IDA Pro**, наиболее продвинутый дизассемблер из имеющихся на данный момент [10]. Позволяет дизассемблировать, отлаживать и модифицировать приложения для большого количества платформ в интерактивном режиме. Для выполнения примеров и заданий настоящей лабораторной работы более чем достаточно функционала свободно распространяемой версии **IDA Free**.

Интерфейс **IDA** достаточно интуитивен, ответы на возникающие вопросы можно уточнить в справке самого приложения, на официальном сайте, либо в неофициальном (но де-факто стандартном) руководстве [11].

Процедура установки **IDA Free** на ОС Windows интуитивна и обычно не требует дополнительных действий (достаточно запустить инсталлятор и следовать инструкциям на экране), на ОС Linux установка может выглядеть примерно следующим образом:

```
x@vbox:~$ cd ~/Downloads
x@vbox:~/Downloads$ chmod u+x ida-free-pc_90_x64linux.run
x@vbox:~/Downloads$ ./ida-free-pc_90_x64linux.run
x@vbox:~/Downloads$
x@vbox:~/Downloads$ mkdir -p ~/.idapro
x@vbox:~/Downloads$ cp idafree_*.hexlic ~/.idapro/
```

[N.B.] Версия 9.0 актуальна на момент написания данного текста, проверьте текущую актуальную версию перед установкой.

На рабочем столе появится иконка «**IDA Free 9.0**», для запуска **IDA** с её помощью необходимо разрешить запуск из контекстного меню: правая клавиша мыши -> Allow Launching.

Если (скорее всего) **IDA** после установки не запустится, проверьте, каких плагинов QT не хватает:

```
x@vbox:~/Downloads$ QT_DEBUG_PLUGINS=1 ~/ida-free-pc-9.0/ida
```

Если в выводе вы увидите строку наподобие “libxcb-xinerama.so.0: cannot open shared object file: No such file or directory”, требуется доставить библиотеку libxcb-xinerama:

```
x@vbox:~/Downloads$ sudo apt install libxcb-xinerama0
```

## 1. Идентификация функций и локальных переменных

Функция – основная структурная единица процедурных, объектно-ориентированных и функциональных языков программирования, используемая для структурирования кода программы. Понятие функция весьма расплывчато, и понимаемое под этим термином зависит от языка программирования. Мы будем считать, что функция – это некоторая обособленная последовательность команд. Функция может принимать аргументы, а может и не принимать; функция может возвращать результат выполнения, а может и не возвращать. Характерная особенность функции – она может вызываться из различных мест программы, а по завершению работы функции управление передаётся обратно на место её вызова. Способы передачи аргументов и возвращения значения будут рассмотрены в следующем разделе, пока же исследуем типичную структуру функции и механизм возвращения управления.

В большинстве случаев, для вызова функции и возвращению из неё компиляторы используют команды **call** и **ret**, соответственно. Определить начало функции можно исходя из того, что, как было сказано выше, функция вызывается из других участков программы, следовательно, если какой-то адрес используется в качестве аргумента инструкции **call**, то, скорее всего, это начало функции [12]. Однако, существует немалое количество способов неявного вызова функций, называемых *косвенными*: в частности, так вызываются т.н. виртуальные функции, вызовы по указателю на функцию и т.п. Эти специальные (специфические) способы вызова мы затрагивать не будем. Когда выполнение программы доходит до команды **call**, исполняющая среда (процессор) понимает, что сначала необходимо передать управление на адрес, по которому располагается функция, а по завершению выполнения этой функции – вернуть управление на место вызова. Разумеется, управление возвращается не на ту же инструкцию **call** (что привело бы к заикливанию программы), а на инструкцию, следующую за ней. Это осуществляется через стек: адрес инструкции, следующей за **call**, помещается на стек (вершина стека в зависимости от разрядности исполняемого файла уменьшается на 4 или 8 байт и на выделенное место копируется адрес – то же, что делает **push addr**), вызываемая функция отрабатывает и в конце выполняет команду **ret** или **retn**, которая извлекает адрес (как это делает команда **pop**) и передаёт управление на этот адрес.

Большинство компиляторов (по крайней мере без оптимизаций) помещают в начало функции т.н. *пролог* функции [13], назначение которого состоит в том, чтобы:

- сохранить значения всех регистров, используемых в коде функции
- выделить место на стеке для локальных переменных, это место называется *кадр стека*.

Локальные переменные функции располагаются в соответствующем ей кадре стека. Для адресации (доступа) конкретных переменных может быть использован регистр **ebp/rbp**, либо же непосредственно сам регистр **esp/rsp**. Характер использования адресованных переменных даёт подсказку о типе этой переменной (например, если 4 байта из кадра стека загружаются в регистр **eax**, то, скорее всего, тип этой переменной – *int*). В конце выполнения функция должна "вернуть всё как было": извлечь свой кадр из стека (ещё говорят "закрыть кадр"), возвращая вершину стека на прежнюю позицию (обычно это выполняется командой **add esp, N**, либо же командой **leave**), а также восстановить значения регистров (с помощью команды **pop**). Совокупность команд, выполняющих данные операции, называется *эпилог* [13].

Посмотрим на описанные части функции в дизассемблере, для этого скомпилируем программу 1.c:

```
double func()
{
    char str[] = "This is a local string";
    char* p = "This is NOT a local string, a pointer is local though";
    int l0, l1, l2, l3, l4, l5 = 5;
```

```

        short l6 = 1;
        return 4.0;
    }

    int main()
    {
        int local1, local2 = 55;
        long local3 = 0;
        float local4 = 0.0, local5 = 3.14;
        double local6 = 2.7, ret = 0.;
        ret = func();

        return 0;
    }

```

с помощью **gcc**:

```

x@vbox:~/lab2$ cd examples
x@vbox:~/lab2/examples$ gcc -g -m32 -fno-PIC 1.c -o 1 -no-pie

```

Исследуем полученный исполняемый бинарный файл под x86. Ниже приведена дизассемблированная функция *func* (откройте скомпилированный файл 1 в IDA и найдите функцию *func*).

```
func proc near
```

```

str= byte ptr -37h
p= dword ptr -20h
l0= dword ptr -1Ch
l1= dword ptr -18h
l2= dword ptr -14h
l3= dword ptr -10h
l4= dword ptr -0Ch
l5= dword ptr -8
l6= word ptr -2

```

|       |                                 |                                       |
|-------|---------------------------------|---------------------------------------|
| push  | ebp                             | ; начало пролога функции              |
| mov   | ebp, esp                        |                                       |
| sub   | esp, 40h                        | ; выделение памяти для                |
|       |                                 | ; локальных переменных                |
|       |                                 | ; далее инициализация переменных      |
| mov   | eax, ds:dword_8048546           |                                       |
| mov   | dword ptr [ebp+str], eax        | ; копирование символов строки на стек |
| mov   | eax, ds:dword_804854A           |                                       |
| mov   | dword ptr [ebp+str+4], eax      |                                       |
| mov   | eax, ds:dword_804854E           |                                       |
| mov   | dword ptr [ebp+str+8], eax      |                                       |
| mov   | eax, ds:dword_8048552           |                                       |
| mov   | dword ptr [ebp+str+0Ch], eax    |                                       |
| mov   | eax, ds:dword_8048556           |                                       |
| mov   | dword ptr [ebp+str+10h], eax    |                                       |
| movzx | eax, ds:word_804855A            |                                       |
| mov   | word ptr [ebp+str+14h], ax      |                                       |
| movzx | eax, ds:byte_804855C            |                                       |
| mov   | [ebp+str+16h], al               |                                       |
| mov   | [ebp+p], offset aThisIsNotALoca | ; эта строка хранится в сегменте      |
|       |                                 | ; данных, но указатель char* p        |
|       |                                 | ; есть локальная переменная           |
|       |                                 | ; поэтому хранится на стеке           |
| mov   | [ebp+15], 5                     | ; int l5 = 5                          |
| mov   | [ebp+16], 1                     | ; short l6 = 1                        |
| fld   | ds:dword_8048560                | ; возвращаемое значение, через        |

|                                    |  |
|------------------------------------|--|
| <pre> leave retn  func endp </pre> | <pre> ; стек для чисел с плавающей ; точкой, т.к. регистра xmm0 ; в архитектуре x86 нет  ; извлечь адрес возврата и ; перейти на место вызова функции </pre> |
|------------------------------------|--|

Первые три инструкции – пролог функции, в нём выполняется подготовка к адресации локальных переменных с помощью регистра **ebp** (сохраняется его значение **push ebp** и копируется текущая вершина стека **mov ebp, esp**), затем выделяется место для локальных переменных командой **sub esp, 40h**. Именованные строки в начале функции – это подсказки от **IDA**, которая создаёт их в процессе автоматического анализа функции (определяя количество и расположение переменных). Эти подсказки содержат название переменной (если оно известно), размер переменной в байтах и смещение переменной от конца области локальных переменных, адрес которого хранится в **ebp**. Например, подсказка **I5= dword ptr - 8** означает, что локальная переменная под названием **I5** занимает 4 байта и смещена на 8 байт вверх от **ebp**, то есть её адрес **ebp-8**. Для повышения читаемости числовое смещение меняется на метку. Адресация локальных переменных в данной функции осуществляется с помощью регистра **ebp** следующим образом. Регистр **ebp** указывает на самый низ участка памяти, отведённого для локальных переменных. Когда нам необходимо получить или изменить значение переменной, мы отнимаем нужное смещение от регистра **ebp** и получаем адрес этой переменной. Например, переменная **I5** смещена на 8 байт относительно конца области локальных переменных (на который указывает регистр **ebp**), поэтому для инициализации **I5** мы используем следующую команду: **mov [ebp+I5], 5**. Обращение к остальным локальным переменным осуществляется так же, только меняется значение смещения и, возможно, размер операндов. На рис. 1 показано расположение локальных переменных на стеке и их значения после выполнения пролога и кода инициализации переменных.

| Выражение в IDA | Реальное выражение | Стек                       | Комментарии   |
|-----------------|--------------------|----------------------------|---|
| ebp+str         | ebp - 0x37         | "This is a local string\0" | char str[] = "This is a local string"   |
| ebp+p           | ebp - 0x20         | 0x8048510                  | char* p = "..."   |
| ebp+l0          | ebp - 0x1C         | ?                          | int l0  |
| ebp+l1          | ebp - 0x18         | ?                          | int l1  |
| ebp+l2          | ebp - 0x14         | ?                          | int l2  |
| ebp+l3          | ebp - 0x10         | ?                          | int l3  |
| ebp+l4          | ebp - 0xC          | ?                          | int l4  |
| ebp+l5          | ebp - 0x8          | 0x5                        | int l5 = 5  |
| ebp+l6          | ebp - 0x2          | 0x1                        | short l6 = 1  |
|                 | ebp                | 0x8048425                  | ebp указывает на это место - на низ области памяти, отведённой на локальные переменные; здесь хранится адрес возврата |

Рис. 1. Стек после пролога функции и инициализации переменных

## 2. Соглашения о вызове функции и возвращаемом значении

### Идентификация аргументов функций

Существуют три способа передачи аргументов функции [12, 14]: через *стек*, через *регистры* и *комбинированный* (через стек и через регистры). Аргументы могут передаваться *по значению* и *по ссылке*. В первом случае передаётся копия соответствующей переменной, а во втором – указатель на переменную (т.е. адрес этой переменной в памяти).

Если для передачи аргументов используется стек (в ассемблерном листинге программы мы увидим команды **push** и **pop**), то по завершении работы вызываемой функции стек необходимо выровнять (вернуть регистру **rsp** значение до вызова функции). Это может быть сделано как в вызываемой функции, так и в вызывающей.

Имеется несколько стандартизованных способов передачи аргументов в функцию. Они называются *соглашения о вызове (calling conventions)*:

1. *C-соглашение* (`__cdecl`): аргументы помещаются в стек справа налево в порядке их объявления (последний аргумент помещается на стек первым), очистка стека возлагается на вызывающую функцию.
2. *Pascal-соглашение* (Pascal, WINAPI): аргументы помещаются в стек слева направо в порядке их объявления (первый аргумент помещается на стек первым), стек очистка очищает вызывающая функция.
3. *Стандартное соглашение* (`__stdcall`): гибрид `__cdecl` и Pascal, аргументы помещаются на стек справа налево, но стек очищает сама вызываемая функция.
4. *Соглашение быстрого вызова*: аргументы передаются через регистры.
5. *AMD64 ABI*. Предыдущие соглашения используются только в архитектуре x86. В архитектуре x86-64 используется следующее правило: аргументы передаются через регистры в установленном порядке (он зависит от операционной системы). Если количество аргументов превышает некоторое установленное значение, то остальные аргументы передаются через стек. Кто в этом случае очищает стек также зависит от ОС и компилятора.

Посмотрим на эти соглашения в дизассемблере. Для начала скомпилируем следующую программу под архитектуру x86 с помощью компилятора **gcc**.

[N.B.] Для удобства можно воспользоваться сайтом Compiler Explorer [15], позволяющим в одном окне браузера видеть исходный код на ЯВУ и соответствующий ассемблерный листинг, скомпилированный с заданными ключами (параметрами) компиляции. Однако рекомендуется выполнить описанные ниже шаги с помощью **gcc** и **gdb/IDA**, дабы привыкнуть к интерфейсу этих программ.

```
int __attribute__((cdecl)) cdecl_call(int a1, int a2, int* a3, char* a4, float a5,
double a6, double* a7, unsigned char a8)
{
    return 4;
}

int __attribute__((stdcall)) stdcall_call(int a1, int a2, int* a3, char* a4, float a5,
double a6, double* a7, unsigned char a8)
{
    return 4;
}
```

```

    int __attribute__((fastcall)) fastcall_call(int a1, int a2, int* a3, char* a4, float
a5, double a6, double* a7, unsigned char a8)
    {
        return 4;
    }

int main()
{
    int lvar3 = 55, ret1 = 0, ret2 = 0, ret3 = 0;
    double lvar7 = 5.435;
    ret1 = cdecl_call(55, 66, &lvar3, "cdecl_call", 4867, 4861574.24, &lvar7, 0);
    ret2 = stdcall_call(56, 67, &lvar3, "stdcall_call", 4868, 4861575.24, &lvar7,
1);
    ret3 = fastcall_call(57, 68, &lvar3, "fastcall_call", 4869, 4861576.24, &lvar7,
0);

    return 0;
}

```

Для компиляции программы под 32-битную архитектуру, необходимо дополнительно указать ключ `-m32` для `gcc`:

```

x@vbox:~/lab2/examples$ gcc -o 2 -g -m32 -fno-PIC -mrtld 2.c -no-pie
x@vbox:~/lab2/examples$

```

Откроем полученный исполняемый файл 2 в **IDA**. Так как мы скомпилировали файл с отладочными символами (с ключом `-g`), мы можем видеть названия аргументов, помещаемых на стек при вызове функции. Перейдём в функцию `main`. Участок кода, в котором происходит вызов функции `cdecl_call`, принимающей аргументы в соответствии с соглашением `cdecl`, выглядит следующим образом:

```

sub     esp, 4Ch
...
dword ptr [esp+20h], 0           ; a8
lea     eax, [ebp+lvar7]
mov     [esp+1Ch], eax           ; a7
fld     ds:dbl_8048610
fstp    qword ptr [esp+14h]      ; a6
mov     eax, 45981800h
mov     [esp+10h], eax           ; a5
mov     dword ptr [esp+0Ch], offset a4
lea     eax, [ebp+lvar3]
mov     [esp+8], eax             ; a3
mov     dword ptr [esp+4], 42h    ; a2
mov     dword ptr [esp], 37h     ; a1
call    cdecl_call
mov     [ebp+ret1], eax           ; возвращаемое значение

```

В комментариях справа указано, какие параметры помещаются на стек в соответствующих командах. Как видно, компилятор сначала зарезервировал на стеке место для локальных переменных и для аргументов (командой **sub esp, 4Ch**). Затем на стек копируются аргументы функции `cdecl_call` справа налево в порядке их объявления. На момент выполнения **call** стек выглядит примерно так, как на рис. 2.

Напомним, что команда **push** уменьшает значение регистра **esp/rsp** на 4 или 8 байт (для 32-битных и 64-битных исполняемых файлов, соответственно), то есть сдвигает вершину стека, и затем копирует данные на эти 4 или 8 байт. Таким образом, последовательное выполнение команд **push** с аргументами функции, выполняемое справа налево в порядке их объявления, приведёт к тому, что значения аргументов будут копироваться на стек друг под другом, и к моменту выполнения инструкции **call** стек процесса будет

|           |            |   |
|-----------|------------|---|
|           |            |   |
| esp       | 0x37       | a1 = 55                                 |
| esp + 4h  | 0x42       | a2 = 66                                 |
| esp + 8h  | ebp-0x18   | a3 = &lvar3                             |
| esp + Ch  | 0x80485E0  | a4 = "cdecl_call"                       |
| esp + 10h | 0x45981800 | a5 = 4867.0                             |
| esp + 14h | 0x8F5C28F6 | a6 = 4861574.24                         |
|           | 0x41528BA1 |   |
| esp + 1Ch | ebp-0x20   | a7 = &lvar7                             |
| esp + 20h | 0x0        | a8 = 0                                  |
|           |            | локальные<br>переменные и др.<br>данные |

Рис. 2. Стек на момент выполнения инструкции call

выглядеть точно также, как на рис. 2. В вызываемой функции стек не очищается (используется команда **retn**).

```

cdecl_call proc near
    ...
    leave
    retn

```

Функция `stdcall_call` принимает аргументы в соответствии с соглашением `stdcall`, а значит аргументы записываются на стек в таком же порядке, что и для функции `cdecl`, в чём можно легко убедиться, посмотрев на участок кода, предшествующий её вызову:

```

mov     dword ptr [esp+20h], 1           ; a8
lea     eax, [ebp+lvar7]
mov     [esp+1Ch], eax                   ; a7
fld     ds:dbl_8048618
fstp    qword ptr [esp+14h]              ; a6
mov     eax, 45982000h
mov     [esp+10h], eax                   ; a5
mov     dword ptr [esp+0Ch], offset aStdcall_call ; a4
lea     eax, [ebp+lvar3]
mov     [esp+8], eax                     ; a3
mov     dword ptr [esp+4], 43h           ; a2
mov     dword ptr [esp], 38h            ; a1
call    stdcall_call
sub     esp, 24h
mov     [ebp+ret2], eax

```

Однако, в отличие от соглашения `cdecl`, в соглашении `stdcall` вызываемая функция должна очистить стек самостоятельно, то есть "вытолкнуть" все аргументы из стека (или же просто увеличить значение регистра **esp** на суммарный размер всех аргументов). Команда **retn N**, совмещает извлечение адреса возврата и выталкивание *N* байт из стека, таким образом:



```

stdcall_call proc near
    ...
    leave
    retn 24h

```

функция `stdcall_call` очищает стек по завершении своей работы, в полном соответствии с соглашением.

Соглашение `fastcall` очень сильно зависит от операционной системы, для которой компилируется исполняемый файл, используемого компилятора и самой функции, поэтому действительный способ передачи аргументов всегда разный.

Теперь рассмотрим передачу аргументов в 64-битных исполняемых файлах. Порядок передачи аргументов по соглашению *AMD64 ABI* в ОС Linux следующий:

#### целочисленные аргументы и указатели (аргументы, передаваемые по ссылке)

1. **rdi**
2. **rsi**
3. **rdx**
4. **rcx**
5. **r8**
6. **r9**
7. 7-й и все последующие аргументы передаются через стек.

#### аргументы – числа с плавающей точкой одинарной или двойной точности

1. нецелочисленные аргументы с 1-го по 16-й передаются через регистры **xmm0-xmm15**
2. остальные аргументы передаются через стек.

Скомпилируем следующую программу (3.c)

```

double func(int a1, int a2, int* a3, char* a4, float a5, double a6, double* a7, unsigned
char a8, int a9)
{
    return 4.0;
}

int main()
{
    int lvar3 = 55;
    double lvar7 = 5.435, ret = 0.;
    ret = func(55, 66, &lvar3, "func", 4867, 4861574.24, &lvar7, 0, 100);

    return 0;
}

```

с отладочными символами:

```

x@vbox:~/lab2/examples$ gcc -o 3 -g -fno-PIC 3.c -no-pie
x@vbox:~/lab2/examples$

```

Убедимся в описанном выше правиле:

```

lea     rax, [rbp+lvar7]
mov     rdx, 41528BA18F5C28F6h
lea     rsi, [rbp+lvar3]
mov     dword ptr [rsp], 64h          ; a9
mov     r9d, 0                       ; a8

```

```

mov     r8, rax                                ; a7
mov     [rbp+var_28], rdx
movsd   xmm1, [rbp+var_28]                    ; a6
movss   xmm0, cs:dword_400670                 ; a5
mov     ecx, offset a4
mov     rdx, rsi                                ; a3
mov     esi, 42h                               ; a2
mov     edi, 37h                               ; a1
call    func
movsd   [rbp+var_28], xmm0

```

Обратите внимание на то, как передаются аргументы *a1* и *a2* – так как это переменные типа *int* (4 байта), то из значения передаются не через **rdi** и **rsi**, а через **edi** и **esi**. Указатель *a3* передаётся через **rdx**. Так как целочисленных аргументов у функции 7, то аргумент *a9* (7-й целочисленный) передаётся через стек: `mov dword ptr [rsp], 64h`. Нецелочисленные аргументы *a5* и *a6* передаются через регистры **xmm0** и **xmm1**.

### Передача возвращаемого значения

Обычно возвращаемое значение передаётся следующим образом:

- если возвращаемое значения – целочисленный тип (*unsigned char, char, short, ..., int, ..., unsigned long, size\_t*), тогда значение передаётся через регистр **eax/rax**
- если возвращаемое значение – указатель, то он также передаётся через **rax**
- если возвращаемое значение – нецелочисленный тип (*float, double*), значение передаётся через регистр **xmm0**.

## 3. Идентификация основных конструкций языков C и C++

### Операторы ветвлений и цикл for

В настоящем разделе мы кратко рассмотрим типичные способы компиляции некоторых выражений языка C (и C++). Конкретный вид получаемого ассемблерного листинга сильно зависит от компилятора и архитектуры процессора [12]. Скомпилируем следующую функцию.

```

#include <stdio.h>

int main()
{
    int i = 0;
    int v1 = 5, v2 = 5, v3_1 = 1, v3_2 = 2, v4_1 = 2, v4_2 = 1;
    int v5 = 1;
    //
    // if clauses
    //
    // 1st if
    if (v1 == 5)
        printf("%s\n", "First if expression (v1 == 5) resolved to true");

    // 2nd if
    if (v2 == 6)
        printf("%s\n", "Second if expression (v2 == 6) resolved to true");
    else
        printf("%s\n", "Second if expression (v2 == 6) resolved to false");

    // 3rd if
    if (v3_1 == 1 && v3_2 == 2)

```

```

        printf("%s\n", "Third if expression (v3_1 == 1 && v3_2 == 2) resolved
to true");
    else
        printf("%s\n", "Third if expression (v3_1 == 1 && v3_2 == 2) resolved
to false");

    // 4th if
    if (v4_1 == 1)
        printf("%s\n", "Fourth if expression (v4_1 == 1) resolved to true");
    else if (v4_2 == 2)
        printf("%s\n", "Fourth if expression (v4_2 == 2) resolved to true");
    else
        printf("%s\n", "Fourth if expressions resolved to false");

    //
    // switch clause
    //
    switch (v5)
    {
        case 0:
            printf("%s\n", "switch-case expression for v5 == 0");
            break;

        case 1:
            printf("%s\n", "switch-case expression for v5 == 1");
            break;

        case 2:
            printf("%s\n", "switch-case expression for v5 == 2");
            break;
    }

    //
    // for clause
    //
    for (i = 0; i < 100; i++)
    {
        printf("i = %d\n", i);
    }

    return 0;
}

```

Скомпилируем следующим образом:

```

x@vbox:~/lab2/examples$ gcc -o 4 -g -m32 -fno-PIC 4.c -no-pie
x@vbox:~/lab2/examples$

```

Дизассемблируя с помощью **IDA**, мы можем видеть листинг в виде графа потока управления.

Рассмотрим первый *if* (рис. 3). Переменная *v1* сравнивается с 5 командой **cmp**. Если *v1* и 5 не равны, то условие – ложь, управление передаётся на метку loc\_8048417 командой **jmp** (переход по зелёной стрелке). Иначе условие - истина, поэтому переход не выполняется и вызывается функция *printf*.

Второй *if* (рис. 4) организован примерно так же, как и первый. Блоки, соответствующие истинной и ложной ветке кода, располагаются вслед за командой **cmp**, друг под другом. Переменная *v2* сравнивается с 6 командой **cmp**. Если *v2* и 6 не равны, то условие – ложь, управление передаётся на метку loc\_8048433

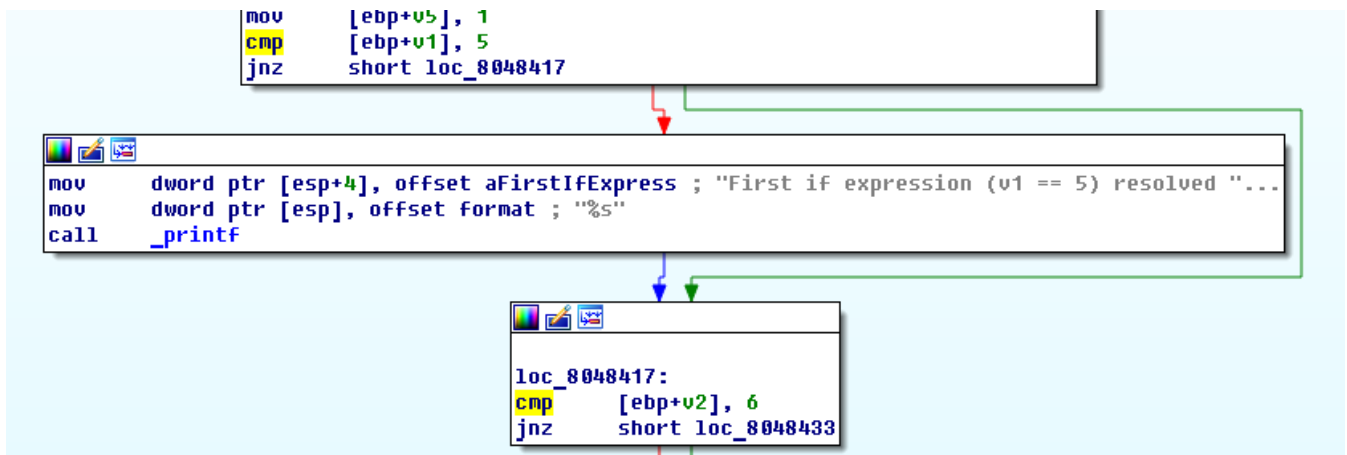


Рис. 3. Граф потока управления первого *if*

командой **jmp** (переход по зелёной стрелке). Если же  $v2 == 5$ , то переход не выполняется и вызывается функция *printf*. Однако, чтобы не выполнять ложную ветку *if*, необходимо эту ветку "перепрыгнуть" – это делается командой **jmp short loc\_808447**.

В третьем *if'e* проверяется два условия. На рис. 5 показан граф этого *if*. Если  $v3\_1 != 1$  или  $v3\_2 != 2$ , то выполняется переход на метку *loc\_804869* (командой **jmp short loc\_808469**). Этой метке соответствует

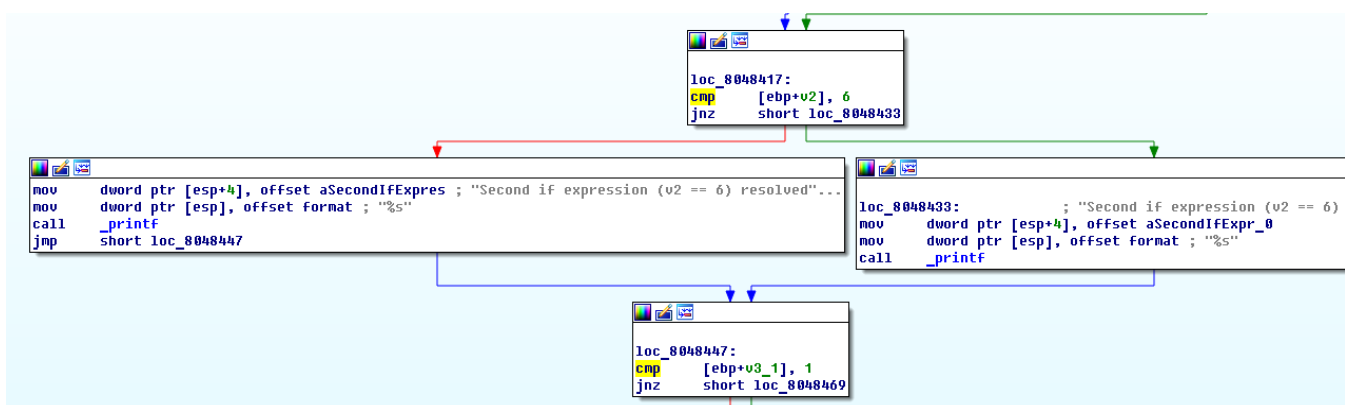


Рис. 4. Граф потока управления второго *if*

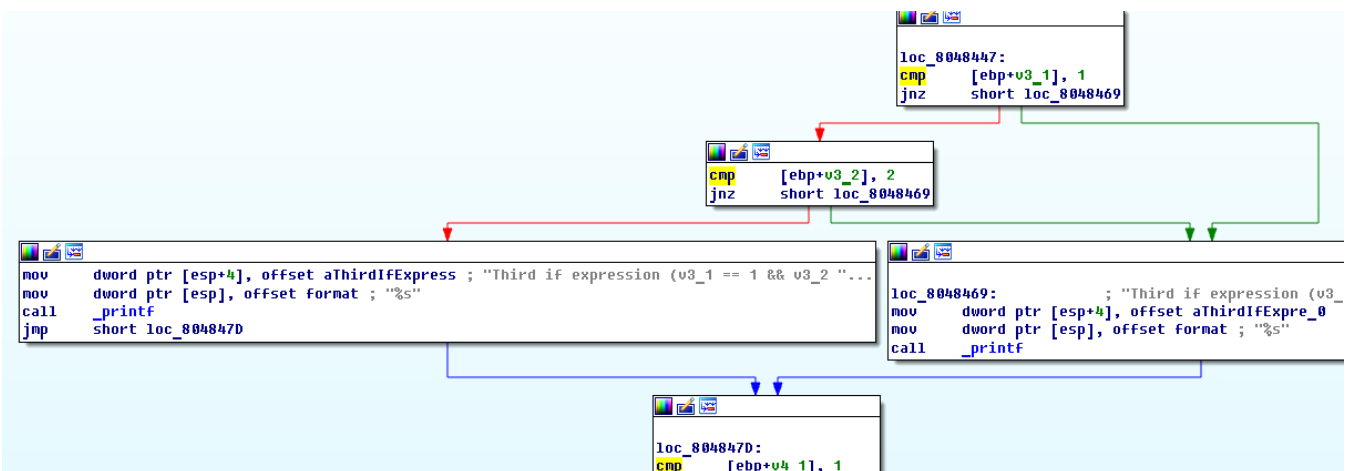


Рис. 5. Граф потока управления третьего *if*

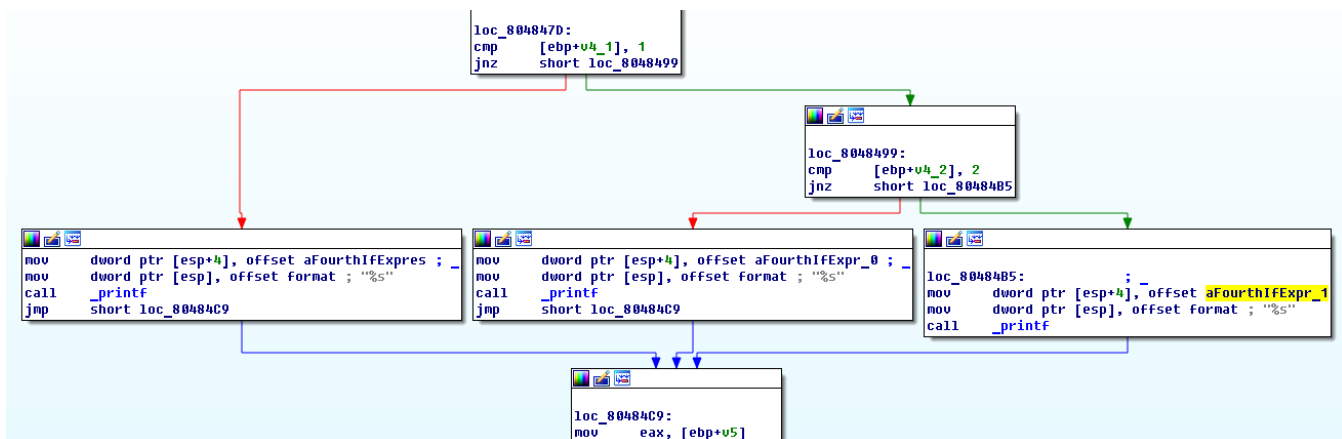


Рис. 6. Граф потока управления четвёртого *if*

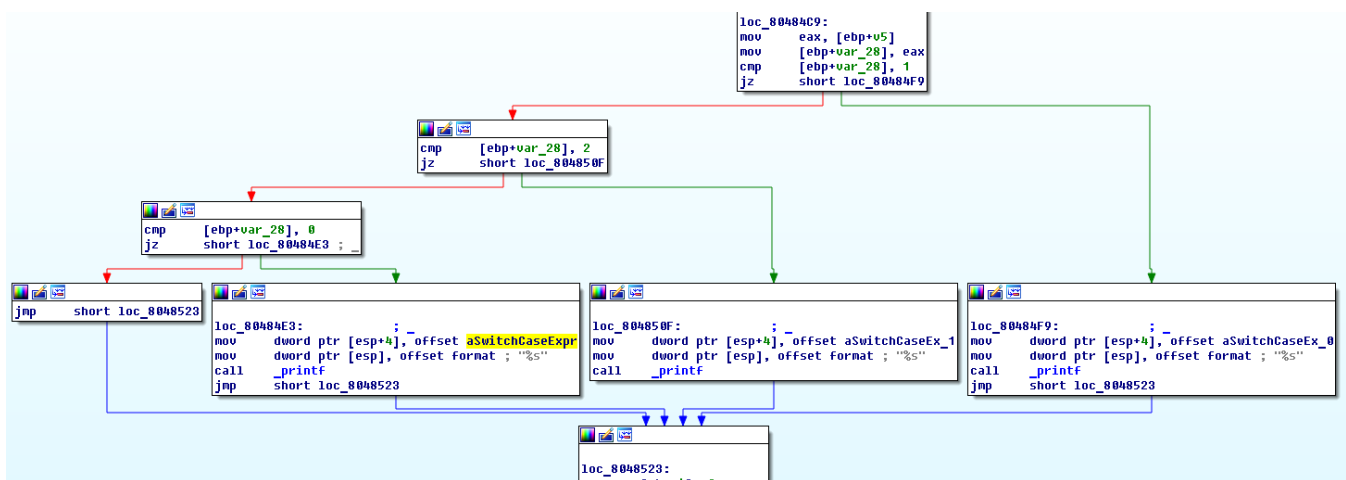


Рис. 7. Граф потока управления *switch-case*

ложная ветвь оператора *if*, т.к. согласно законам де Моргана  $A \text{ and } B == \text{not } A \text{ OR not } B$ . Если перехода не произошло, выполняется истинная ветвь оператора *if*. Оба блока располагаются точно также, как и в предыдущем случае.

В четвёртом *if* (рис. 6) также проверяются два условия. Если  $v4\_1 == 1$ , то переходим по красной стрелке: выполняется *printf*, далее переход на конец оператора (**jmp short loc\_80484C9**). Если же первое условие не выполняется, проверяем второе командой **cmp [ebp+v4\_2], 2**, при этом граф выглядит также, как и в случае второго *if*. Все три блока кода располагаются друг под другом.

Оператор *switch-break* (рис. 7) обычно реализуется как последовательность операторов *if*, поэтому ассемблерный листинг и граф потока управления практически идентичен графу предыдущего, четвёртого *if*.

В тестовой программе оператор *for* скомпилировался в очень простую последовательность команд (рис. 8). Сначала переменная-счётчик *i* инициализируется (обнуляется), далее проверяется условие  $i < 100$ , если оно истинно, то переходим на метку **loc\_804852C** и вызываем *printf*. Команда **cmp [ebp+i], 63h** располагается сразу под этим блоком. Когда  $i < 100$  перестаёт быть истиной, не переходим на метку, таким образом мы выходим из цикла.

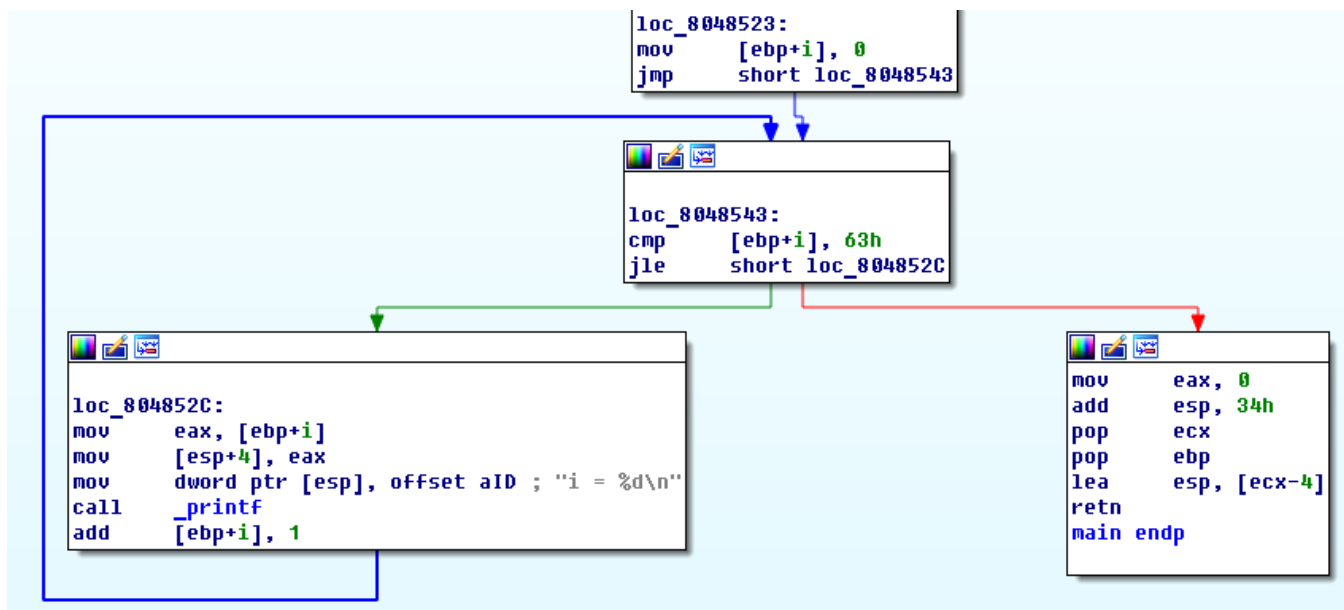


Рис. 8. Граф потока управления *for*

Как можно убедиться из приведённых выше примеров, типичные операторы C (C++) транслируются компилятором в достаточно чёткие и понятные последовательности команд.

### Структуры и объекты классов

С точки зрения организации данных в памяти, объекты классов C++ ничем не отличаются от структур языка C. Рассмотрим на следующем примере, как располагаются поля структуры в памяти процесса [12]. Скомпилируем следующую программу:

```

#include <string.h>

struct MyStruct
{
    int a;
    long b;
    float c;
    double d;
    char e[10];
    int* f;
    MyStruct* pNext;
};

class MyClass
{
public:
    int a;
    long b;
    float c;
    double d;
    char e[10];
    int* f;
    MyClass* pNext;

public:
    MyClass()
    {

```

```

        this->a = 1;
        this->b = 2;
        this->c = 3.0;
        this->d = 4.0;
        memset(this->e, '5', sizeof(this->e));
        this->f = 0;
        this->pNext = 0;
    }
};

int main()
{
    MyStruct strct;
    MyClass cls;
    strct.a++;
    strct.d += 5.0;
    cls.a++;
    cls.d += 5.0;
    return 0;
}

```

в этот раз с помощью *g++*, без отладочных символов:

```

x@vbox:~/lab2/examples$ g++ -o 5 -m32 -fno-PIC 5.c -no-pie
x@vbox:~/lab2/examples$

```

Дизассемблированная в *IDA* функция *main* выглядит следующим образом:

```

main proc near

var_54= dword ptr -54h
var_48= qword ptr -48h
var_2C= dword ptr -2Ch
var_20= qword ptr -20h
argc= dword ptr 0Ch
argv= dword ptr 10h
envp= dword ptr 14h

        lea     ecx, [esp+4]
        and     esp, 0FFFFFF0h
        push    dword ptr [ecx-4]
        push    ebp
        mov     ebp, esp
        push    ecx
        sub     esp, 54h
        lea     eax, [ebp+var_54]
        mov     [esp], eax                ; this
        call    MyClass::MyClass(void)
        mov     eax, [ebp+var_2C]
        add     eax, 1
        mov     [ebp+var_2C], eax
        fld     [ebp+var_20]
        fld     ds:dbl_8048598
        faddp   st(1), st
        fstp    [ebp+var_20]
        mov     eax, [ebp+var_54]
        add     eax, 1
        mov     [ebp+var_54], eax
        fld     [ebp+var_48]
        fld     ds:dbl_8048598
        faddp   st(1), st

```

```

        fstp      [ebp+var_48]
        mov       eax, 0
        add       esp, 54h
        pop       ecx
        pop       ebp
        lea       esp, [ecx-4]
        retn
main endp

```

Сначала командой **sub esp, 54h** резервируется место по две структуры: структуру типа *MyStruct* и объект класса *MyClass*. Поля структуры типа *MyStruct* не инициализируются, а для объекта класса *MyClass* вызывается конструктор. В качестве единственного аргумента конструктору передаётся указатель *this* – указатель на область памяти, в которой располагается сам объект.

Рассмотрим функцию `MyClass::MyClass(void)`:

```
MyClass::MyClass(void) proc near
```

```
this= dword ptr 8
```

```

        push     ebp
        mov      ebp, esp
        mov      eax, [ebp+this]           ; аргумент функции - конструктора
        mov      dword ptr [eax], 1
        mov      eax, [ebp+this]
        mov      dword ptr [eax+4], 2
        mov      edx, [ebp+this]
        mov      eax, 40400000h
        mov      [edx+8], eax
        mov      eax, [ebp+this]
        fld      ds:dbl_8048590
        fstp     qword ptr [eax+0Ch]
        mov      eax, [ebp+this]
        add      eax, 14h
        mov      dword ptr [eax], 35353535h
        mov      dword ptr [eax+4], 35353535h
        mov      word ptr [eax+8], 3535h
        mov      eax, [ebp+this]
        mov      dword ptr [eax+20h], 0
        mov      eax, [ebp+this]
        mov      dword ptr [eax+24h], 0
        pop      ebp
        retn     MyClass::MyClass(void) endp

```

Очевидно, что команды

```

        mov      eax, [ebp+this]
        mov      dword ptr [eax], 1

```

соответствуют оператору `this->a = 1`. Таким образом, первое поле типа *int* хранится в первых 4 байтах объекта класса, так как в **eax** помещается адрес начала объекта и по этому адресу записываются 4 байта – **dword ptr**.

Команды

```

        mov      eax, [ebp+this]
        mov      dword ptr [eax+4], 2

```



соответствуют оператору `this->b = 2` (*int* и *long* одинакового размера на *x86*). Значит, второе поле хранится по смещению 4 байта от начала объекта и также занимает 4 байта.

Команды

```
mov     edx, [ebp+this]
mov     eax, 40400000h
mov     [edx+8], eax
```

записывают 4 байта по смещению 0x8 байт от начала объекта; 0x40400000 – это шестнадцатеричное представление числа 3.0. То есть эти команды соответствуют выражению `this->c = 3.0`, а поле `c` класса *MyClass* хранится в 4 байтах и смещено на 8 байт от начала объекта.

Команды

```
mov     eax, [ebp+this]
add     eax, 14h
mov     dword ptr [eax], 35353535h
mov     dword ptr [eax+4], 35353535h
mov     word ptr [eax+8], 3535h
```

соответствуют выражению `memset(this->e, '5', sizeof(this->e))`. Поле `e` расположено по смещению 0x14 от вершины объекта.

Команды

```
mov     eax, [ebp+this]
mov     dword ptr [eax+20h], 0
mov     eax, [ebp+this]
mov     dword ptr [eax+24h], 0
```

соответствуют операторам `this->f = 0` и `this->pNext = 0`. То есть, поля *f* и *pNext* располагаются по смещениям 0x20 и 0x24, причём это указатели, а потому занимают по 4 байта. Необходимо отметить, что смещение поля `e` равно 0x14, а смещение поля `f` – 0x20, то есть между ними 12 байт, хотя поле `f` есть массив из 10 байтов (`char e[10]`). Поля располагаются таким образом потому, что по умолчанию для ускорения работы с памятью поля выравниваются на границу слова – в данном случае, на 4 байта. Ниже в комментариях справа от полей написаны найденные смещения.

```
class MyClass
{
public:
    int a;                /*0x0*/
    long b;               /*0x4*/
    float c;              /*0x8*/
    double d;             /*0xC*/
    char e[10];           /*0x14*/
    int* f;               /*0x20*/
    MyClass* pNext;      /*0x24*/
    ...
}
```

Как можно видеть из второй части ассемблерного листинга функции *main*, доступ к полям структуры *MyStruct* осуществляется аналогично.

## Задания

1. Напишите простейшую программу на C, в которой определена функция с аргументами, возвращаемым значением и локальными переменными, и эта функция вызывается из функции *main* (можно взять первый пример). Запустите скомпилированную программу под отладкой (например, с помощью **IDA** или **gdb**) и наблюдайте за стеком во время вызова функции и возвращения после её выполнения на место вызова. Найдите на стеке передаваемые аргументы, сохраняемый адрес возврата и все её локальные переменные.
2. Напишите программу на ассемблере, в ней определите функцию, принимающую аргументы не в соответствии с каким-либо соглашением (например, через другие регистры) и возвращающую несколько значений в регистрах. Используйте **IDA** и дизассемблируйте программу, затем декомпилируйте вашу функцию. Поняла ли **IDA**, как именно вы передаёте аргументы в функцию и возвращаете значения? Распознала ли она какое-нибудь соглашение по вызову функций?
3. Скомпилируйте все примеры из раздела "**Операторы ветвлений и цикл for**". Запустите их на отладку (с помощью **IDA** или **gdb**) и проследите за состоянием регистров **eip** и **eflags** при выполнении операций ветвления в программе.
4. Напишите и скомпилируйте программу на C с циклами *while* и *do-while*. Дизассемблируйте эту программу с помощью **IDA** и определите, как организованы эти циклы на ассемблере.
5. Скомпилируйте пример из раздела "**Структуры и объекты классов**". Запустите на отладку (с помощью **IDA** или **gdb**) и проследите за значениями полей объекта класса *MyClass* в процессе работы конструктора. найдите поля структуры *MyStruct* на стеке функции *main*.
6. В соответствии с номером варианта, дизассемблируйте с помощью **IDA** скомпилированный исполняемый файл %N%. Восстановите вид используемых структур/классов и логику работы приложения. Используйте полученный код для написания собственной программы, выполняющей те же действия, что и исходная программа.

## Литература

1. [https://www3.ntu.edu.sg/home/ehchua/programming/cpp/gcc\\_make.html](https://www3.ntu.edu.sg/home/ehchua/programming/cpp/gcc_make.html)
2. <https://gcc.gnu.org/onlinedocs/>
3. <https://developers.redhat.com/blog/2021/04/30/the-gdb-developers-gnu-debugger-tutorial-part-1-getting-started-with-the-debugger>
4. <https://developers.redhat.com/articles/2022/01/10/gdb-developers-gnu-debugger-tutorial-part-2-all-about-debuginfo>
5. <https://developers.redhat.com/articles/2022/11/08/introduction-debug-events-learn-how-use-breakpoints>
6. <https://developers.redhat.com/articles/2021/10/05/printf-style-debugging-using-gdb-part-1>
7. <https://developers.redhat.com/articles/2021/10/13/printf-style-debugging-using-gdb-part-2>
8. <https://developers.redhat.com/articles/2021/12/09/printf-style-debugging-using-gdb-part-3>
9. <http://gnu.ist.utl.pt/software/gdb/documentation/>
10. <https://hex-rays.com/ida-pro/>
11. Chris Eagle. The IDA Pro Book, 2nd Edition: The Unofficial Guide to the World's Most Popular Disassembler
12. Касперски К. Искусство дизассемблирования. БХВ-Петербург, 2009
13. [https://en.wikipedia.org/wiki/Function\\_prologue\\_and\\_epilogue](https://en.wikipedia.org/wiki/Function_prologue_and_epilogue)
14. [https://en.wikipedia.org/wiki/Calling\\_convention](https://en.wikipedia.org/wiki/Calling_convention)
15. <https://godbolt.org/>
16. Эрикссон Д. Хакинг: искусство эксплойта. 2-е издание. Символ, 2010